纽约时报新闻文本分类：词袋、词向量与 BERT 的比较

自然语言处理课程 作业一

摘要

我们在同一份 NYT 数据划分上比较了六种文本表示：二值词袋与词频词袋、三种词向量平均（预训练 GloVe、在 AG News 上训练的 Word2Vec、在 NYT 上训练的 Word2Vec），以及微调后的 BERT。除 BERT 外的五种表示统一搭配逻辑回归。本报告的结构有一点不同于常规：我们在动手之前先依据原理写出五条可证伪的预测，实验之后逐条核对，最后专门剖析预测与结果不一致的地方。五条预测中三条成立，两条被推翻。

最重要的一条出现在 BERT 上。作业规定的 `max_length=64` 使 BERT 只能读到每篇文档的头部，而 NYT 文档的中位长度是 768 个词元。我们用一个前缀长度扫描实验把这一截断的代价单独测量出来：在表示固定为词袋的条件下，截断到 64 个词会使宏平均 F1 下降 0.0456，信息直到约 512 个词才饱和。把 BERT 的截断长度改为 512、其余设置不变，宏平均 F1 由 0.9623 升到 0.9823，由低于大多数经典配置变为高于全部经典配置。因此“词袋胜过 BERT”这个表面结论并不成立，它比较的是读过全文的词袋和只读十分之一篇幅的 BERT。

1 引言

本报告要回答的问题是：更好的文本表示，在这个任务上能否换来更好的分类效果。

作业把六个实验分成三组，下文分别简称 Task 1（两种词袋）、Task 2（三种词向量平均）、Task 3（BERT 微调）。三者依次丢弃得更少：词袋丢弃词序与词间的语义关联，词向量平均补回了语义但仍丢弃词序，BERT 两者都不丢。

我们尽可能只让表示这一个因素变化：分类器、数据划分、超参数的选取方式都固定。这个控制在 BERT 上并不完全成立，6 节会说明它的比较还多带了一个变量，以及我们如何处理。

2 数据与实验设置

六个实验共用同一份数据和同一套评价方式，本节把这些先固定下来。

表 1: NYT 语料按类别统计。长度一律按 nltk 词元计。

类别	篇数	占比	中位长度	平均长度
体育	8,639	75.0%	757	715
政治	1,451	12.6%	815	822
财经	1,429	12.4%	739	730
全部	11,519	100.0%	768	730

2.1 数据与划分

NYT 语料共 11,519 篇文档，分属三个数量极不均衡的类别：体育 8,639 篇（占 75.0%）、政治 1,451 篇（12.6%）、财经 1,429 篇（12.4%）。文档普遍很长：词元数中位数 768，第 90 百分位 1093，最长 5,977 个。全文的“词数”一律按 nltk 分词后的词元数计（同一份语料按空白切分，中位数是 672 而不是 768，两者差约一成半）。

课程提供的 AG News 文件 (Zhang et al., 2015) 含 90,000 条短新闻，词数中位数 39，本作业中它只用来训练一组词向量。

各类别的规模与长度见表 1。我们先在固定随机种子下打乱 NYT 语料，再按 80/10/10 划分，得到 9,215 篇训练、1,151 篇验证、1,153 篇测试。测试集中体育 864 篇、政治 152 篇、财经 137 篇；后文按篇数统计误差时用的就是这个分布。划分结果写成三个文件，后面所有实验都读取这三个文件而不是各自重划。验证集只用于两处超参选择：逻辑回归的正则强度，以及 BERT 取哪一轮的权重。测试集在每个实验的最后读取一次。

2.2 评价指标与平凡基线

我们报告准确率与宏平均 F1。先说一个参照点：一个永远预测体育的分类器可以得到 0.7493 的准确率，但两个少数类的 F1 都是 0，宏平均 F1 只有 0.2856。后文每一个准确率都应参照这个数字来读。

2.3 重复运行

单次运行的结果里，有些差距小到可能只是随机波动。为此我们对带随机性的配置做了重复运行，报告时给出区间而不是单点。

词袋加逻辑回归没有随机性——词表、优化、正则强度的选取都是确定的——所以 Task 1 的数字可精确复现，两条曲线之间的差距不含噪声。

GloVe 同样没有随机性，它只是查一张固定的预训练词表。我们特意用另一个种子重跑了一次以验证这一点，两次的宏平均 F1 都是 0.9666 与 0.9666，完全一致。

Word2Vec 与 BERT 则带有随机性。这两组我们各跑了三个种子；后文所说的“区间”就是三个种子的最小到最大值，不是统计意义上的置信区间。本节自设的门槛是“差距小于 0.005 不做强断言”；当某个配置的种子跨度本身超过 0.005 时（BERT 的 64 子词配置即如此），以区间是否重叠为准。

3 实验前的理论预测

这一节是动手之前写下的五条预期，每条都写明它依赖的机制。先写下来是为了让它们可证伪：事后解释总能自圆其说，先摆出预测，才知道哪条推理真的站得住，以及被推翻时断的是哪一环。

预测一：宏平均 F1 普遍低于准确率。 本任务 75% 的样本属于体育类，模型会偏向多数类。准确率对每个样本一视同仁，会被多数类拉高；宏平均 F1 对三类等权，少数类上的错误不会被多数类摊薄。因此我们预期每一组实验里都有 宏平均 F1 $<$ 准确率。

预测二：二值词袋追平甚至略微超过词频词袋。 判断一篇新闻是不是体育类，关键在于文中是否出现了 *players*、*league*、*coach* 这类判别性强的词。这些词出现过一次，信号就已经很强。作业中的词频表示只统计绝对次数，没有做归一化，长文档里那些高频但与主题无关的词会在线性打分时被放大，扰乱权重的更新。所以两者应当很接近，二值词袋甚至可能更稳。

预测三：三种词向量的排序是 GloVe 优于 W2V(NYT)，W2V(NYT) 优于 W2V(AG News)。 这条预测依赖两个方向相反的机制。数据规模方面，Word2Vec 需要大量语料才能把每个词的向量学准，而词频服从齐夫定律（极少数词出现极多，绝大多数词只出现寥寥几次），判别性强的词往往落在只出现几次的长尾上；我们手上的 NYT 训练集（9,215 篇）是 6,734,438 个词元，官方 GloVe 6B 的语料约 60 亿词，相差约 890 倍。按 Banko 与 Brill 的经验法则 (Banko and Brill, 2001)，大规模通用语料学出的特征通常优于小规模领域语料上从零训练的特征。领域契合方面，NYT 训练的向量是领域内的，AG News 虽然也是新闻，但与 NYT 存在分布差异。两者相权，我们预测数据规模这一边胜出，得到 GloVe 第一、W2V(NYT) 第二、W2V(AG News) 第三。

预测四：词袋可能追平甚至反超词向量平均。 词袋的 $|V|$ 维稀疏空间里，每个词占据一个独立的坐标轴，互不干扰，命中一个强类别词就能立刻给出判断。词向量平均则是一个低通滤波器：一篇中位长度（约 768 词元）的新闻，把几百个向量求平均之后，大量高频但语义稀薄的词会稀释掉少数几个决定主题的关键词的向量。因此我们预期 Task 2 不会比 Task 1 拉开多少，甚至可能被反超。

预测五：BERT 断层式领先，且截断的损失有限。 微调会让梯度回传到表示层本身，而前五个实验的表示对下游任务是盲的，这应当带来明显优势。至于 `max_length=64` 的截断，我们预期损失不大，理由是西方新闻写作普遍采用倒金字塔结构，最要紧的事实集中在导语，前 64 个词应当已经保留了大部分主题信息。相应地，把上限提高到 256 或 512 只会带来“微弱的上升”。

预测汇总。 综合五条，我们预期的名次是：BERT 大幅领先，词袋与 GloVe 接近并排在其次，然后是 W2V(NYT)，W2V(AG News) 垫底。

4 实验

这一节报告三组任务的实现与结果。所有实验共用第 2 节写好的那一份划分。

4.1 Task 1：词袋模型

我们用 `nltk.word_tokenize` 分词并保留标点（作业只提到该分词器，没有要求进一步过滤）。词表*只在训练集上*构建，若在全集上构建，测试集的词汇会进入特征空间。在 `min_df=1` 下词表规模为 127,352，这是作业所说“整个训练语料的词表”的字面实现。附录中我们用 `min_df=5` 重做了两个实验，说明这个选择不影响结论。

二值词袋把文档表示为 $|V|$ 维向量，第 i 个分量为 1 当且仅当词表中第 i 个词出现。词频词袋的同一位置存的是该词的出现次数。

这里的 `min_df` 是 sklearn 的文档频率下限：一个词至少要在这么多篇训练文档里出现过才会进入词表，注意它与 Task 2 中 gensim 的 `min_count`（最小词频）是两个不同的量。

两者的分类器都是逻辑回归，正则强度 C 在 $\{0.1, 1, 10, 100\}$ 中按验证集的宏平均 F1 选取。需要留意 sklearn 的 C 是正则强度的倒数，C 越大正则越弱。稀疏矩阵不做标准化。

两种表示在测试集上都取得 0.9887 的准确率，差别只在宏平均 F1：二值的 0.9744 略高于词频的 0.9728，差距是 0.0016（表 2）。

4.2 Task 2：词向量平均

词表大小记作 $|V|$；Word2Vec 在图表中简记为 W2V。

每篇文档表示为其所有在词表中出现过的词的 100 维向量的平均，$\mathbf{e}(d) = \frac{1}{n}\sum_{i=1}^{n}\mathbf{e}(w_i)$。作业没有规定均值之后还要做什么，我们把稠密向量做零均值、单位方差的标准化再送入逻辑回归；Task 1 的稀疏矩阵没有做这一步。下面比较三个向量来源。

预训练 GloVe(Pennington et al., 2014) 使用官方发布的 `glove.6B.100d`，不做任何针对本任务的调整。

在 AG News 上训练的 Word2Vec(Mikolov et al., 2013) 使用跳元模型，即用中心词预测其上下文的窗口，向量维度 100，窗口 5，最小词频 5，训练 5 轮。语料是 90,000 条 AG News 文本，与 NYT 同属新闻，但来自不同的分布。

在 NYT 上训练的 Word2Vec 参数相同，但语料限定为*训练集*。作业只说“使用 NYT 文本数据”，没有限定范围，这是我们的一个选择，需要说明：Word2Vec 是无监督模型，用整个 NYT 训练不会泄漏标签，但测试集文档会参与生成用来分类它们自己的向量，评测就带上了对测试集的适配。限定在训练集上可以消除这个问题，也保证三个变体可比。

因为一篇文档在没有任何词命中词表时会退化为零向量，覆盖率界定了每种词向量能发挥作用的范围。这里覆盖率指的是训练集全部词元中能在词表里查到向量的比例（分母是词元出现次数之和，不是不同词型的个数）。三种向量的覆盖率并不相同，见表 3，其中 AG News 训练出的向量明显偏低，原因是 NYT 的许多词汇并不出现在 90,000 条短新闻里。

三个来源的语料都用 `nltk.word_tokenize` 分词。三个来源的宏平均 F1 跨度是 0.0141，排在最前的是 NYT 训练的 Word2Vec，最后的是 AG News 训练的 Word2Vec。

4.3 Task 3：BERT 微调

我们严格按作业规定微调 `bert-base-uncased`(Devlin et al., 2019)：最大序列长度 64，训练 3 轮，批次大小 32，优化器 AdamW，学习率 2×10^{-5}，前 10% 的步数做线性预热。取验证集宏平均 F1 最好的那一轮用于测试。

`max_length=64` 在这个语料上意味着：词元数中位数 768，截断保留头部、丢弃尾部，BERT 大致只看到一篇典型报道的前十分之一。与它比较的词袋和词向量平均读的都是全文。第 6 节会把这一不对称的代价单独测出来。

4.4 全部结果

六种配置连同平凡基线的完整结果见表 4，逐项的准确率与宏平均 F1 对比见图 1，各类别的错误分布见图 2。表中最后三行是附录实验，不属于这六种配置。

5 结果与预测的对比

这一节把第 3 节的五条预测与第 4 节的结果逐条对上。三条成立，两条被推翻——被推翻的正是事前写得最具体的那两条，这大概也是先写预测的价值所在。

本节与下一节会反复引用带随机性配置的多种子区间，这些数字见表 6；表中的「种子 1」即主结果表 4 所用的 seed 42，后两列是另跑的种子。

5.1 成立的三条

预测一成立。 六组配置全部满足宏平均 F1 低于准确率，差距从 0.0143 到 0.0240 不等。差距最大的是 W2V（AG News，100 维），它的准确率与宏平均 F1 相差 0.0240。这符合预期：多数类占了四分之三，模型只要把多数类做对，准确率就会很高，而少数类的错误被准确率平均掉了，却会在宏平均 F1 上完整暴露。

预测二成立，但量级可以忽略。 二值词袋在测试集上得到 0.9744，词频词袋得到 0.9728，差距 0.0016。

这里需要交代一处不完全干净的地方，否则这个差值会被高估。两者的正则强度 C 是在验证集上各自选出来的，而*验证集给出的排序与测试集相反*：验证集上词频词袋是 0.9705，高于二值词袋的 0.9610，因此词频选了更大的 C。测试集上两者却调换了次序，而差距只有 0.0016。换言之，这个差值建立在一个与测试集判断不一致的验证集选择之上。第 2 节说词袋管线没有随机性，指的是给定这套设定后结果可精确复现，不是指两条表示之间的比较不受超参选择影响。

结论因此要弱读：在未归一化的词频表示下，词频这一项没有带来可分辨的额外信息，二值与词频在本任务上应视为等价。

表 2: Task 1 的结果（末列为验证集，其余为测试集）。两种表示共用同一份含 127,352 个词的训练词表，区别只在每个位置上存什么值。

表示方法	C	准确率	宏平均 F1	验证集宏平均 F1
二值词袋	0.1	0.9887	0.9744	0.9610
词频词袋	1	0.9887	0.9728	0.9705

表 3: 三种词向量对 NYT 训练集的覆盖率。覆盖率界定每种词向量能起作用的范围：一篇文档若所有词都不在词表中，其文档向量会退化为零向量，而三种词向量下这样的文档数都是零。

词向量来源	词表规模	词元覆盖率
GloVe 6B	400,000	0.9807
Word2Vec（AG News）	25,376	0.9426
Word2Vec（NYT）	31,574	0.9795

预测四成立：两者处于同一水平。 词袋没有随机性，它的 0.9744 是一个定值；NYT 训练的 Word2Vec 三个种子落在 0.9710 到 0.9755，词袋正好落在这个区间之内。同一随机种子下两者的差距是 0.0001。因为一侧是定值、另一侧有波动，这里不适合比较“两者各自的最好值”，那样会把波动算成表示之间的差异。可以下的判断是：词向量平均没有拉开优势，严格讲也不是“词袋反超”。这里要留意，这一条只在宏平均 F1 上成立：按准确率，NYT 词向量的 0.9905 反而略高于词袋的 0.9887。一种解释是词袋用 $|V|$ 个独立坐标轴直接对应关键词的机制，与词向量平均把关键词稀释在低通滤波里的机制在这个任务上相互抵消——这只是解释，我们没有做能把两种机制分开的实验。

5.2 被推翻的两条

预测三被推翻：前两名调换了位置。 我们预测 GloVe 依靠数据规模胜出。实际结果是 NYT 训练的 Word2Vec 最好，GloVe 居中，AG News 训练的 Word2Vec 最差。三个种子下 NYT 训练的取值落在 0.9710 到 0.9755，AG News 训练的落在 0.9604 到 0.9616，GloVe 是没有随机性的定值 0.9666。GloVe 恰好落在另外两者的区间之间，与两边都不重叠。也就是说，预训练词向量被两个自训练词向量夹在中间，我们预测的第一名掉到了第二名。这个结果说明在这一档数据规模上，领域契合至少没有输给数据规模。需要立刻补上一句限定：胜出的余量并不大，第 6 节会说明这个结论能推到哪里为止。

预测五被推翻，而且是两处同时失效。 我们预测 BERT 断层式领先，同时预测 64 个词的截断损失有限。实际上 BERT 以 0.9623 的宏平均 F1 排在末两位，比最好的经典方法低 0.0122。而把截断长度从 64 提到 512、其余设置一律不变，宏平均 F1 从 0.9623 升到 0.9823，提高了 0.0200，BERT 随即超过 0.9745 升到第一。所以两条子预测都错了：领先没有出现，截断的损失也远不是“微弱”。

6 预测与结果不一致的剖析

上一节核对出的两个矛盾各有其成因，本节逐个定位到推理链上出问题的那一环。先看预测三——它的失效发生在推理的输入端。

6.1 “数据规模压制领域偏差”为什么没有生效

预测三的前提是：NYT 训练集太小，Word2Vec 学不准判别性强的词，所以宁可用大规模通用语料训出来的词向量，哪怕带一点领域偏差。这个前提有两半，逐半检查。

第一半：平均池化只用得上高频词。 文档向量是词向量的算术平均，出现一两次的生僻词对结果的贡献被 $1/n$ 稀释掉，决定文档方向的是反复出现的高频词。而判别三个类别的词恰恰高频：表 7 列出每类中权重最高的四个词及其频率，出现最少的一个也有 1,341 次，是 `min_count=5` 门槛的约 268 倍。

齐夫长尾造成的欠拟合落在低频词上，而低频词在这个池化方式下本来就不起作用。预测所依赖的失效机制在本任务上没有多少作用面。这证明的是判别词高频，不是“若它们低频会怎样”——两者不是一回事。

第二半：领域偏差被高估。 GloVe 6B 的语料是 2014 年的英文维基百科加 Gigaword(Pennington et al., 2014)，而 Gigaword 本身就是通讯社新闻语料库 (Graff and Cieri, 2003)。下游语料谈论的年份也落在相近的时段：提及最多的年份是 2011，2010 至 2014 年占 9,075 次年份提及的 44.6%（图 3）。

年份提及不等于发稿年份，所以这个统计只界定时间重心的下界。它能支持的结论是：下游语料谈论的事件落在 GloVe 训练窗口覆盖的

表 4: 全部结果，均在共用的 NYT 测试集（1,153 篇）上测得。表中每个数字都由 `scripts/collect_results.py` 从 `results/` 生成。对带随机性的配置，此处列的是首个种子（seed 42）的取值；多种子区间在正文第 5 与 6 节给出。

任务	配置	准确率	宏平均 F1	财经 F1	政治 F1	体育 F1
参照	平凡基线（全猜 sports）	0.7493	0.2856	0.0000	0.0000	0.8567
Task 1	二值词袋	0.9887	0.9744	0.9549	0.9711	0.9971
	词频词袋	0.9887	0.9728	0.9591	0.9610	0.9983
Task 2	GloVe 6B（100 维）	0.9861	0.9666	0.9442	0.9579	0.9977
	W2V（AG News，100 维）	0.9844	0.9604	0.9377	0.9446	0.9988
	W2V（NYT，100 维）	0.9905	0.9745	0.9591	0.9644	1.0000
Task 3	BERT-base（64 子词，3 轮）	0.9818	0.9623	0.9386	0.9545	0.9936
附录	二值词袋（min_df=5）	0.9887	0.9744	0.9549	0.9711	0.9971
	词频词袋（min_df=5）	0.9887	0.9745	0.9588	0.9675	0.9971
	BERT-base（512 子词，3 轮）	0.9931	0.9823	0.9704	0.9772	0.9994

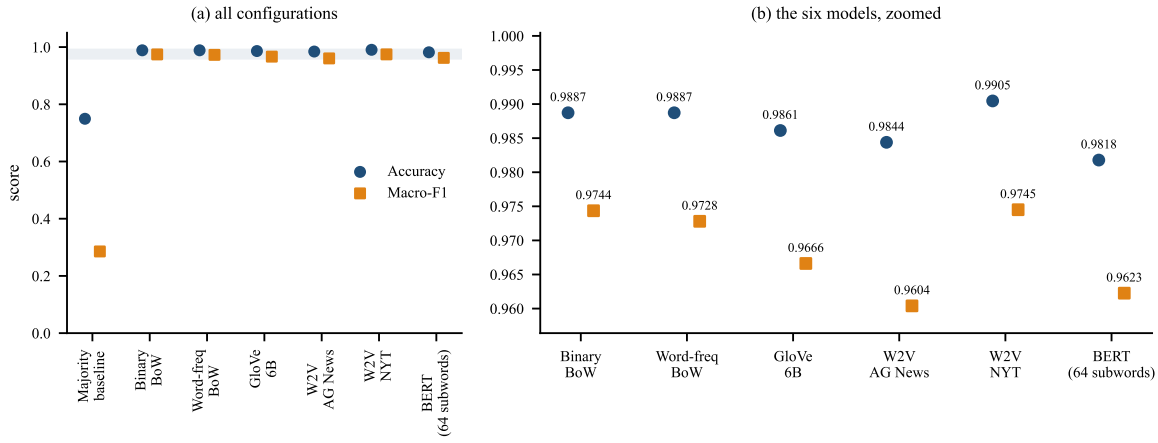


图 1: 各配置的准确率与宏平均 F1。(a) 七种配置放在同一根 0–1 的轴上，阴影带标出六个模型占据的区间：它们在轴的顶端挤成一条窄带，而平凡基线远在下方。(b) 去掉基线、放宽纵轴以容纳六个模型的全部取值（0.96 到 1.00），它们之间的次序这才看得出来——圆点是准确率，方点是宏平均 F1。单张图做不到这两件事：0–1 的范围下六个模型不可区分，缩放到窄带后基线会落到轴外。

表 5: 测试集上误差的归属（单位：篇），*按真实类别分组*：三列分别是真实为财经、政治、体育的文档中被误判到其他类的篇数，一格一个数。图 2 按行归一化展示，比例会被类别规模掩盖，这里换算成篇数。

配置	财经	政治	体育
BERT（64 子词）	7	5	9
二值词袋	10	1	2
W2V（AG）	9	7	2

年份里，领域偏差更可能来自文体与词表差异，而非时代错位。

两点交代。 覆盖率可以排除一种解释：三种词向量的词元覆盖率分别是 0.9807、0.9795、0.9426（表 3），前两者几乎相同，所以 GloVe 与 NYT 词向量的差距不在“这个词有没有向量”。

表 6: 带随机性配置的重复运行，每格是一个种子的宏平均 F1。词袋与 GloVe 没有随机性，表中未列，其数值是定值。

配置	种子 1	种子 2	种子 3
W2V（NYT）	0.9745	0.9755	0.9710
W2V（AG News）	0.9604	0.9616	0.9615
BERT，64 词	0.9623	0.9538	0.9602
BERT，512 词	0.9823	0.9787	0.9800

GloVe 的预训练语料还可能直接包含测试集原文——若 Gigaword 收录了纽约时报，而这份下游语料正是纽约时报的稿件。这一点无法核查，也找不到干净的否证办法，只能留在原处。它的方向偏保守：泄漏只会抬高 GloVe 的成绩，而 GloVe 仍排在 NYT 自训练的词向量之后。

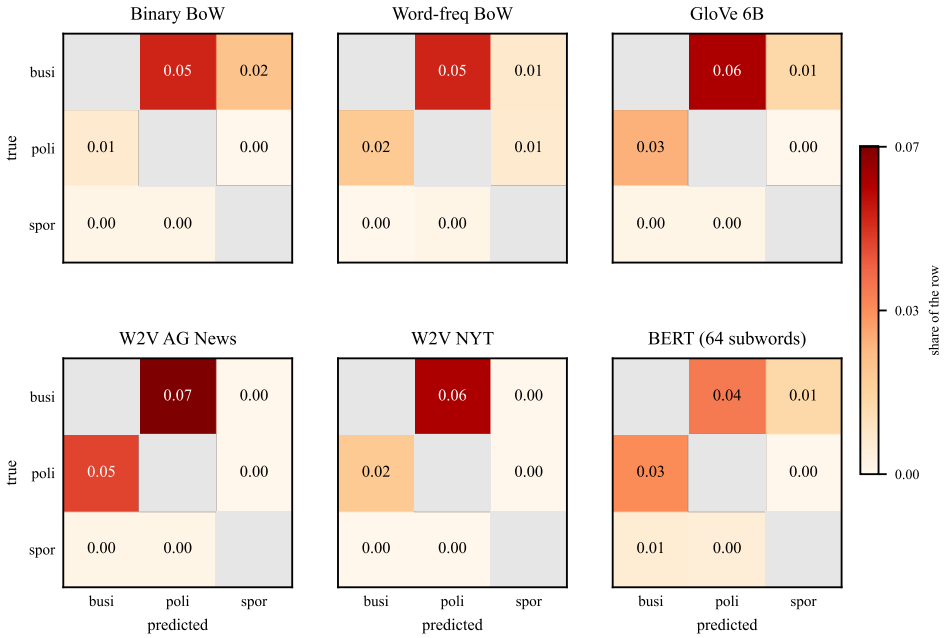


图 2: 测试集上的行归一化混淆矩阵，*对角线已屏蔽*，色标只覆盖非对角线的取值。这样做的原因很实际：对角线在 0.93 以上，与最浅的非对角格子相差一个量级，若把两者放进同一根 0–1 的色标，六个面板会全部呈现为一模一样的深色对角线，而真正承载论证的那些格子都不到 0.10，完全看不见。屏蔽对角线后，财经与政治之间的误判在每一栏都是最深的格子，64 子词的 BERT 那一栏还能看到真实为体育的误判（0.01）。逐配置的篇数见表 5。

最后是这条结论的强度。三个种子下 NYT 训练的最差取值比 GloVe 高 0.0044，两者区间不重叠；按第 2 节的门槛，这个余量属于少数几篇文档的差别。可以断言的是“领域内训练不劣于预训练词向量”，不是“领域内训练稳定胜出”。

6.2 “倒金字塔救了截断”为什么是错的

预测五的第二条依赖一个事实主张：倒金字塔结构把主题信息集中在导语，所以前 64 个词已经够用。这是可以直接测量的。

先量截断的代价。 直接拿 BERT 与词袋比会同时变两件事——表示能力，与模型看到的词数。要分离后者，先让*同一个*分类器去吃文档的不同前缀：固定用二值词袋加逻辑回归（Task 1 中最强的配置，且没有随机性），把每篇文档截到前 N 个词，扫描 N。表示不变，曲线随 N 的变化就只能归因于可见的信息量；这里用“能读到的词数”作信息量的代理指标。

结果见表 8 与图 4。前 64 个词只保留了 0.9288 的宏平均 F1，比读全文低 0.0456；信息量要到 512 个词附近才饱和。

导语确实浓缩了主题，但“浓缩”不等于“完整”：一篇中位长度的报道里，用于分类的信息有相当一部分落在前 64 个词之外。倒金字塔那条推理把“文章开头最重要”这个写作学事实，当成了“开头包含足够用于分类的信息”这个信息论结论。

再量表示能力。 上面只说明词袋读前缀会损失多少，没有回答“同样的输入下 BERT 是否更强”。要让它成为直接测量，得让两个模型读到同一段文本，而这里有一个不能含糊的单位问题：BERT 的 `max_length` 数的是*子词*，词袋那条曲线截断的是*词*。实测前 64 个子词平均只覆盖 54 个词，前 512 个子词覆盖 408 个（`scripts/prefix_units.py`），照名义长度直接对比就是两个单位画在同一条轴上。

所以按*每篇文档*各自被 BERT 前缀覆盖到的词数截断词袋，让两个模型读到同一段文本。结果见表 9：四个匹配点上 BERT 都更高，差值分别是 0.0285、0.0412、0.0145、0.0074。“表示能力更强”至此才是同一输入下的直接测量。

两处细节。表 9 与表 8 的词袋取值不同，因为前者按每篇各自的覆盖词数截断、后者把每篇都截到同一个 N，两套规则不可互推。另外差值并不随可见词数单调收窄：词袋那一侧换

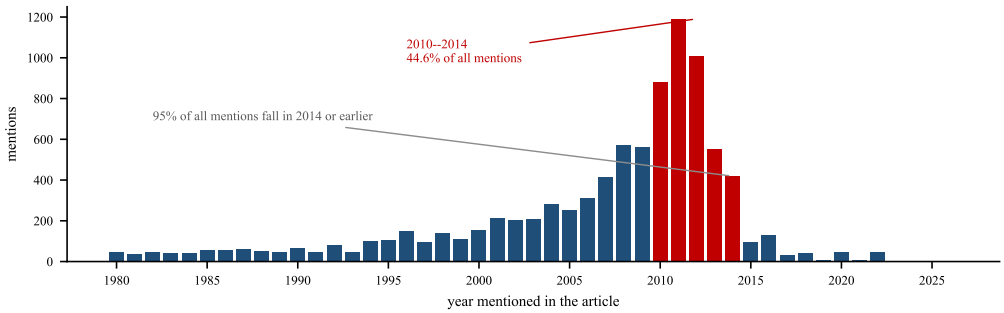


图 3: 训练集中提到的年份分布，按年份升序。红色是正文引用的 2010–2014 窗口，它占全部 9,075 次年份提及的 44.6%。95% 的提及落在 2014 年或更早：这份语料谈论的事件集中在一个 GloVe 6B 训练窗口覆盖的时段里，这正是 “时代错位” 这条解释所能依据的全部内容——它不表明两份语料同属一个时期。

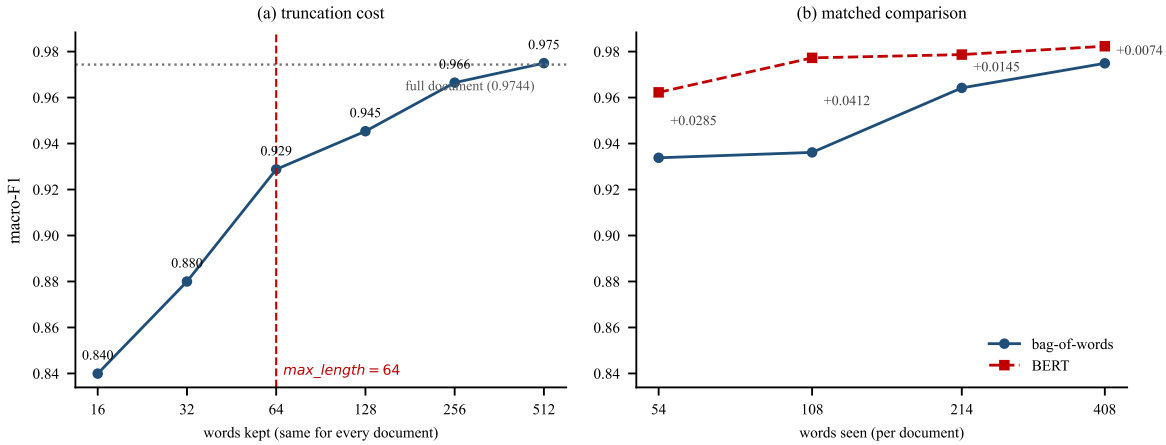


图 4: 两个不同的问题。(a) 截断代价：表示固定为词袋，*每篇文档*都截到同样的 N 个词，曲线说明一篇报道的前 N 个词里有多少可用于分类的信息。(b) 匹配比较：词袋按*每篇文档*实际被 BERT 前缀覆盖的词数截断，两个模型读同一段文本，标注的是两者的差值。两个面板的*横轴含义不同*（前者是每篇都截到同一个 N，后者是各篇实际被覆盖的词数），因此没有画在同一面板里；但两者画的是同一个量（宏平均 F1），所以*共用一个纵轴范围*，以免并排比较时被不同的刻度误导。

一组截断词数再算（54/81/108/162 个词）得到 0.9338、0.9457、0.9361、0.9425，自身就不单调，而 BERT 一侧的四个点单调递增。这个走势因此无从解释，能支持的只是 “每个匹配点上 BERT 都更高，且在最长的两档上差距明显缩小”。

6.3 代价落在哪些文档上

截断的代价不是均匀分布的。表 10 把测试集按词数分成五层，报告每层上两个模型的错误率，以及 BERT 的前缀平均能覆盖该层文档的多大比例。

最明显的反差在第一层：200 词以下 BERT 的错误率是 0.0，词袋是 2.6，因为这一层的前缀就覆盖了 39.7 的内容。但这一层只有 76 篇，两个错误率折成篇数是 0 篇对 2 篇，而相邻的 200 至 400 词层反过来是 1 篇对 0 篇——这个量级的差别在噪声之内。真正站得住的是长文档那一端：700 至 1000 词层有 464 篇文档，词袋错误率 1.3，BERT 是 3.0。

BERT 的错误率在这里不是单调的：700 至 1000 词层最高，更长的层反而略低。这个形状不必解释——五层的错误篇数分别是 0、1、1、14、5，总共 21 篇，层间只差几篇。顺便排除一个候选解释：极长文档并不特别偏向体育，>1000 词层有 208 篇，其中 73% 是体育，与全文的 75% 相当。

一个具体例子。 原始语料中 `idx` 为 5252 的文档是一篇 1,166 词的体育报道（语料行号，不是测试集序号），BERT 判为财经，词袋判对。BERT 只读到前 48 个词：

> edina, minn. — the 95-degree heat on a late august day made josh harding hasten from his cadillac escalade pickup truck into an air-conditioned coffee shop. a few minutes after buying a lemonade, harding — in a white t-shirt, dark blue shorts,

表 7: 每个类别中跳过少量通用词后权重最高的四个词，及其在 9,215 篇训练文档中的*出现次数*与*出现文档数*，末行给出各自的门槛（前者是 Task 2 的 `min_count`，后者是附录的 `min_df`）。词序是模型的权重序，不是频次序。

类别	词	次数	篇数
体育	*players*	7,577	3,202
	league	7,284	3,021
	season	11,719	4,494
	game	17,234	5,013
政治	*washington*	2,937	1,743
	republican	1,466	503
	obama	2,225	649
	law	1,844	801
财经	*company*	2,541	924
	companies	1,409	598
	market	1,558	752
	chief	1,341	945
门槛	–	5	5

表 8: 前缀长度扫描。表示固定为二值词袋加逻辑回归，只有可见的词数变化。这就是 “读一个前缀要付多少代价” 的测量值。

前缀词数	准确率	宏平均 F1	相对全文
16	0.9176	0.8399	-0.1345
32	0.9410	0.8800	-0.0944
64	0.9662	0.9288	-0.0456
128	0.9757	0.9454	-0.0290
256	0.9861	0.9665	-0.0079
512	0.9896	0.9750	+0.0006
全文	0.9887	0.9744	–

flip-flops

这一段里没有任何体育线索。而紧接着的下一个词是 “and a backward minnesota twins ball cap”，随后出现 “the minnesota wild goalie … during the n.h.l. lockout”。判别这篇报道属于体育的标志词恰好落在截断点之后。这个例子只解释 BERT *为什么没有看到体育*，不解释它为什么归到财经。

代价落在哪些文档上，可以做一个差分。 测试集里 “BERT 判错而词袋判对” 的文档共 17 篇（由两个模型的逐文档预测文件对比得出，不在上表中）。按长度分布是 0、1、1、11、4 篇，其中 15 篇落在最长的两层，与上面分层表里 BERT 的错误集中在长文档一致。这组数字是差分对照：同一批文档上 BERT 错而词袋对，所以差异只能来自截断。

6.4 约束条件能推多远

本文比较的是*作业规定的那一组配置*，不是 “词袋优于 BERT”。在中位长度 768 个词元、截断到 64 个子词这两个条件同时成立时，读全文的词袋会赢；把截断放宽，结论立刻反转。若换一个类别词汇交叠更多的语料，方法之间的排序是否会更分明，本报告无从判断——手头只有一份带标签的下游语料。

表 9: 真正同输入下的对比。词袋一侧按*每篇文档*实际被 BERT 前缀覆盖到的词数截断，而不是按同一个名义 N，因为 N 在两侧分别是词与子词。

BERT 前缀（子词）	覆盖词数	词袋	BERT	差值
64	54	0.9338	0.9623	+0.0285
128	108	0.9361	0.9773	+0.0412
256	214	0.9642	0.9787	+0.0145
512	408	0.9749	0.9823	+0.0074

表 10: 测试集按文档长度分层。“可见比例” 是 BERT 的 64 个子词前缀平均覆盖到的文档比例。两个模型的错误率都以该层文档数为分母。

长度（词）	篇数	可见	词袋错	BERT 错
<200	76	39.7%	2.6%	0.0%
200–400	101	17.6%	0.0%	1.0%
400–700	304	9.7%	0.3%	0.3%
700–1000	464	6.5%	1.3%	3.0%
>1000	208	4.9%	1.9%	2.4%
全部	1153	10.2%	1.1%	1.8%

带随机性的配置各跑了三个种子，相邻名次之间小于 0.005 的差距不做强断言。BERT 的 64 子词配置三个种子落在 0.9538 到 0.9623，而 AG News 词向量落在 0.9604 到 0.9616，两个区间*重叠*。所以 “BERT 排在最后” 需要限定：它低于 NYT 词向量（差 0.0122）与二值词袋（差 0.0121）是确定的，与 AG News 词向量、GloVe（差 0.0043）则都不足以强断言。

截断长度这一项相反，是可以强断言的。64 子词配置三个种子落在 0.9538 到 0.9623，512 子词配置落在 0.9787 到 0.9823，两个区间不重叠：拿 512 最差的种子比 64 最好的种子，仍有 0.0164 的差距，且 512 的每一个种子都高于全部经典配置。

7 结论

第一，在这个任务上，经典词袋表示的能力与最好的稠密词向量平均处在同一水平，而它不需要任何预训练权重，训练也不依赖 GPU。三个稠密来源中 AG News 训练的 Word2Vec 明显

表 11: 每个类别权重最高的 50 个词中任意两类的交集大小。这里的词表未剔除任何通用词，唯一的非零交集 *mr.* 正是这一类词；表 7 用的则是剔除后的词表。对角线是类别与自身，最右列各给两个例词。

类别	财经	政治	体育	例词
财经	–	1	0	company、companies
政治	1	–	0	washington、republican
体育	0	0	–	players、league

更低，“同一水平” 不涵盖它。六种配置全部落在 0.9604 到 0.9745 之间，跨度 0.0141；而同一模型内最易的类与最难的类之间，F1 相差 0.0422（以二值词袋为例）。比较表示方法带来多大差别，应当参照前者。这个结果大概来自三类新闻的词汇几乎不重叠，不过这只是一条解释：本报告为 “为什么各方法挤在一起” 给过几种机制，它们都与观察相容，我们没有做能把它们区分开的实验。

第二，宏平均 F1 而非准确率才是有效的指标。平凡基线取得 0.7493 的准确率，却对两个少数类完全无能为力。

第三，先写预测再做实验，在我们这次是有收益的。事前写得最具体的两条预测都被推翻了，推翻它们的过程产生了本报告最有信息量的两个结果。两条观察不足以支撑一条方法学结论，只能算一次经验。

第四，不要把配置限制的后果归于方法本身。BERT 在这份报告里排在末两位，原因不是上下文表示不好，而是它只被允许读文档的十分之一。把截断放宽到 512 个子词，它在每一个种子下都成为最好的配置。任何来自受限配置的实验数字，都是关于那个配置的陈述。

第五，测量要针对机制而不是针对现象。预测五出错的地方，是它用一个写作学观察（导语最重要）替代了一个信息论判断（导语包含足够信息）。补上这一步测量的做法是让同一个分类器去读不同长度的前缀，把信息量这一个变量单独分离出来。

8 复现说明

代码仓库包含完整流程。在项目根目录下依次执行：

- `uv sync`，安装锁定版本的运行环境。
- `uv run python -m scripts.make_splits`，生成共用的 80/10/10 划分。
- `uv run python -m scripts.task1_bow`，Task 1。
- `uv run python -m scripts.task2_embed --variant {glove, w2v_ag, w2v_nyt}`，Task 2。
- `uv run python -m scripts.task3_bert`，Task 3。
- `uv run python -m scripts.truncation_curve`，第 6 节的截断代价扫描（表 8）。
- `uv run python -m scripts.prefix_units` 与 `uv run python -m scripts.matched_prefix`，同一节里子词到词的换算与匹配比较（表 9）。
- `uv run python -m scripts.topic_diagnostics`，第 2 与 6 节用到的判别词、词频与年份统计。
- `uv run python -m scripts.error_analysis`，表 10 的分层错误率与第 6 节的具体误判样例。
- `uv run python -m scripts.collect_results` 与 `uv run python -m scripts.make_figs`，从 `results/` 重新生成本报告的全部表格与插图。
- `./scripts/build_report.sh`，重新生成并编译本文档。

重复运行使用 `--seed` 参数，例如 `--seed 7 --suffix _seed7`。附录实验使用 `--min-df 5` 与 `--max-len 512`。

A 附录

这一节包含一组辅助实验：检验 Task 1 的词表剪枝是否影响结论。（把 BERT 的截断长度放宽到 512 的那组对照，因为与正文第 6 节论证直接相关，已放在附录表 12 的最后一行，正文中随用随引。）

A.1 词表剪枝是否是承重设计

主实验使用 `min_df=1`，即作业 “整个训练语料的词表” 的字面实现，得到 127,352 个词。这么大的词表以只出现一次的词为主，因此我们的结论是否依赖它们需要检验。把 `min_df` 改为 5 之后词表剩下原来的 0.227，宏平均 F1 的变化不超过 0.0017，见表 12。词表剪枝不承重：区分这三个类别的信息集中在常见词里，这与表 11 测出的判别词集一致。需要留意这里用的是哪个量：`min_df` 按*文档频率*剪枝，所以支持 “它们不会被剪掉” 的是出现文档数而非出现次数（第 4 节专门区分过这两个量）。表 7 给出的是 “出现次数/出现文档数”，后者的最小值是 503 篇，因此 `min_df` 取到约 500 都不会剪掉这些词；我们没有试过更激进的剪枝。

附带一点：在 `min_df=1` 下词频词袋略逊于二值词袋，在 `min_df=5` 下反了过来。这个方向反转与第 5 节说的验证集、测试集排序不一致是同一件事：两者的差距本身就落在超参选择的量级内，换个词表阈值就足以改变次序。这也再次说明这两个表示没有实质差别。

表 12: 附录实验。前两行把 Task 1 的 `min_df` 改为 5；最后一行把 BERT 的截断长度改为 512，用于把表示能力与截断的代价分开。

配置	$\lvert V \rvert$	准确率	宏平均 F1
二值词袋，min_df=5	28,938	0.9887	0.9744
词频词袋，min_df=5	28,938	0.9887	0.9745
BERT，max_len 512	–	0.9931	0.9823

References

Michele Banko and Eric Brill. 2001. Scaling to very very large corpora for natural language disambiguation. In *Proceedings of the 39th Annual Meeting of the Association for Computational Linguistics*, pages 26–33.

Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. 2019. BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL)*, pages 4171–4186.

David Graff and Christopher Cieri. 2003. English gigaword. Linguistic Data Consortium, Philadelphia. LDC2003T05.

Tomas Mikolov, Kai Chen, Greg Corrado, and Jeffrey Dean. 2013. Efficient estimation of word representations in vector space. In *Proceedings of the International Conference on Learning Representations (ICLR)*.

Jeffrey Pennington, Richard Socher, and Christopher D. Manning. 2014. Glove: Global vectors for word representation. In *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 1532–1543.

Xiang Zhang, Junbo Zhao, and Yann LeCun. 2015. Character-level convolutional networks for text classification. In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 649–657.